

第三周实验报告

人脸识别模型训练 · 动态量化 · ONNX 部署验证

项目	face-vision-lab
实验阶段	第三周 / 阶段三
实验日期	2026-08-18 - 2026-08-24
计算资源	NVIDIA GeForce RTX 3080
GitHub	github.com/xjyyhero/face-vision-lab

1,000,000

MS1M 训练图像

80.27%

LFW 10 折 Accuracy

3.29×

ONNX CPU 加速

73 min

GPU 训练耗时

报告摘要

本周完成两条实验链路：一是在 MS-Celeb-1M 的真实子集上训练 ResNet50 + ArcFace 人脸识别模型，并按 LFW 标准 10 折协议验证；二是对训练模型执行 PyTorch 动态量化、CPU 性能与精度对比，并导出 ONNX 完成 ONNX Runtime 推理验证。训练流程在两小时预算内完成，ONNX 部署获得明显加速；LFW 精度未达到 98.5% 目标，报告对结果与限制如实分析。

01 本周工作概览

任务	数据集 / 模型	完成内容	核心产出
任务 5 人脸识别	MS-Celeb-1M ResNet50 + ArcFace	RecordIO 读取、训练、曲线、LFW 10 折验证	LFW = 80.27%
任务 6 优化部署	动态 INT8 ONNX Runtime	大小、延迟、精度对比；ONNX 导出与推理	ONNX = 3.29×

完成的工程链路

- 实现无需 MXNet 依赖的 train.rec / train.idx 读取流程，并过滤非图像记录、重映射真实子集身份。
- 完成 ResNet50 512 维特征网络、ArcFace 角度间隔分类头、margin 预热、混合精度训练和检查点保存。
- 完成 LFW deep-funneled 6000 对、10 折阈值选择与水平翻转特征融合验证。
- 完成 Linear 动态量化、FP32 / INT8 CPU 单图延迟与模型大小对比，以及量化后 LFW 复测。
- 完成 opset 17 ONNX 导出、动态 batch 配置、结构检查、数值误差检查和 ONNX Runtime CPU 基准。

实验结论摘要

模型在训练子集上的无 margin 分类 Accuracy 达到 98.91%，但 LFW 仅为 80.27%，说明训练拟合充分而跨身份泛化不足。动态量化几乎保持 LFW 精度，却因只覆盖末端 Linear 层而未获得速度收益；ONNX Runtime 将 CPU 单图延迟从 16.11 ms 降至 4.89 ms，是本实验中更有效的部署路径。

02 实验一：ResNet50 + ArcFace 人脸识别

实验目标

使用 MS-Celeb-1M 的真实子集训练基于 ResNet50 和 ArcFace 损失的人脸识别模型，输出 512 维归一化特征，并在 LFW 上按标准 10 折协议验证。目标 Accuracy 不低于 98.5%。

方法原理

- ResNet50 通过残差连接训练深层特征提取网络，本实验将分类层替换为 512 维嵌入并进行 L2 归一化。
- ArcFace 在正确身份对应角度上加入间隔 m ，再乘尺度 s 后计算交叉熵，以增强类内紧凑性与类间分离度。
- LFW 验证移除 ArcFace 分类头，仅比较两张人脸融合特征的余弦相似度；每折阈值由另外九折选择。

实验环境与训练设置

项目	配置	项目	配置
操作系统	Windows 64-bit	GPU	RTX 3080
Python	3.11	PyTorch / CUDA	2.1.0+cu118 / 11.8
训练图像	1,000,000	训练身份	12,299
模型	ResNet50	Embedding	512
Batch size	128	训练轮数	10 epochs
学习率	0.05 + cosine	Weight decay	0.0005
ArcFace	$s=64, m=0.5$	margin 预热	$0 \rightarrow 0.5 / 3 \text{ epochs}$

02.1 训练过程与收敛结果

10

完整训练 epochs

5.0668

最终 ArcFace Loss

98.91%

最终训练 Accuracy

73.0 min

总训练时间




图 1 ResNet50 + ArcFace 训练 Loss 与无 margin 分类 Accuracy

结果分析

- 第 1 轮 margin=0；第 2、3 轮逐步升至 0.25 和 0.5。第 3 轮 Loss 上升到 20.6530，源于角度约束增强，并非数值异常。
- margin 固定为 0.5 后，Loss 从 20.6530 持续下降至 5.0668，训练 Accuracy 从 81.84% 上升至 98.91%，训练过程稳定收敛。
- 10 轮训练总耗时约 73.0 分钟，平均每轮约 7.3 分钟，满足单张 RTX 3080 的两小时预算。

02.2 LFW 10 折验证结果

80.27%

平均 Accuracy

 $\pm 2.28\%$

折间标准差

98.5%

任务目标

-18.23 pp

与目标差距




图 2 LFW 各折 Accuracy、平均值与目标值

验证协议与结论

- LFW deep-funneled 共 6000 对，每折 600 对；每一折的余弦阈值只由其余九折选择，阈值范围为 0.576~0.583。
- 各折 Accuracy 为 76.17%~84.67%，平均 80.2667% $\pm$ 2.2757%，低于 98.5% 目标 18.23 个百分点。
- 训练 Accuracy 较高而 LFW 明显偏低，表明模型对训练身份的拟合强于对未见身份的泛化。本实验仅覆盖 MS-Celeb-1M 的部分身份，且训练与 LFW 存在数据分布差异。
- 本次结果可证明训练与验证链路完整可复现，但不能宣称模型达到任务要求的最终识别精度。

03 实验二：模型优化与部署准备

实验目标

对任务 5 的 ResNet50 人脸特征模型进行 PyTorch 动态量化，比较量化前后的精度、速度与模型大小；随后导出 ONNX，并使用 ONNX Runtime 验证推理正确性和 CPU 性能。

优化技术说明

- 动态量化：将 Linear 权重保存为 int8，并在推理时动态量化激活。本模型的卷积层保持 FP32。
- 剪枝：移除低重要性权重、通道或结构；只有推理引擎和硬件支持稀疏计算时才可能获得实际加速。
- 知识蒸馏：通过教师模型指导更小的学生模型，在减少参数与计算量的同时尽量保留精度。
- ByteNN：任务中为可选项，本实验未实施，不将其计入完成结果。

基准方法

项目	设置
硬件 / 设备	CPU 单图推理；batch size = 1
输入	随机张量 $1 \times 3 \times 112 \times 112$
预热 / 重复	20 次预热，100 次计时取平均
量化范围	PyTorch 动态量化，仅 nn.Linear
精度复测	与任务 5 相同的 LFW 10 折协议
ONNX	opset 17，动态 batch，CPUExecutionProvider

03.1 量化前后与 ONNX 性能对比

模型	大小	CPU 延迟	LFW Accuracy
PyTorch FP32	93.99 MB	16.11 ms	80.1833% ± 2.3111%
PyTorch 动态 INT8	90.99 MB	17.19 ms	80.2167% ± 2.3083%
ONNX Runtime FP32	93.61 MB	4.89 ms	未复测



图 3 PyTorch FP32、动态 INT8 与 ONNX Runtime 的大小和延迟

结果分析

- 动态量化后模型缩小 3.19%（约 3.00 MB），LFW 变化仅 +0.033 个百分点，精度基本保持。
- 动态 INT8 延迟比 FP32 增加 6.70%。ResNet50 的主要计算来自卷积层，仅量化末端 Linear 不足以获得加速。
- ONNX Runtime 延迟降低 69.63%，约为 PyTorch FP32 的 3.29 倍速度，是本实验中最有效的 CPU 部署方案。

03.2 ONNX 导出与推理验证



图 4 ONNX 导出与验证流程

验证结果

检查项	结果	判定
模型结构	onnx.checker.check_model 通过	通过
动态 batch	输入 / 输出第 0 维设为 batch	通过
数值一致性	最大绝对误差 1.8999e-7	通过
CPU 推理	CPUExecutionProvider 4.89 ms	通过

结论

导出的 `arcface\_resnet50.onnx` 在结构、动态 batch、数值误差和 CPU 推理四项检查中均通过。ONNX 模型保持 FP32 精度语义，且不依赖 PyTorch 运行时，适合作为本实验的部署交付格式。

04 总结、实验改进与下周计划

总结

本周完成从 MS-Celeb-1M RecordIO 读取、ResNet50 + ArcFace GPU 训练、LFW 10 折验证，到动态量化、性能对比、ONNX 导出和 ONNX Runtime 推理的完整链路。训练任务在 73 分钟内完成，ONNX CPU 推理达到 3.29 倍加速；LFW Accuracy 为 80.27%，未达到 98.5% 目标。

任务完成状态

要求	实测结果	状态
ResNet50 + ArcFace 训练	1M 图像 / 12,299 身份 / 10 epochs	完成
LFW Accuracy $\geq$ 98.5%	80.2667% $\pm$ 2.2757%	未达标
动态量化与三项对比	大小、速度、LFW 精度已记录	完成
ONNX 导出与推理	结构、误差、CPU 延迟验证通过	完成
ByteNN	可选项，未实施	未实施

实验局限

局限	影响
身份覆盖	只使用 MS-Celeb-1M 部分身份，跨身份泛化能力受限。
训练预算	10 epochs 在两小时内完成，但不足以代表完整 MS1M 的最佳性能。
量化范围	仅 Linear 动态量化，卷积计算仍为 FP32，无法获得整体 INT8 加速。
基准范围	延迟仅为本机 CPU、batch=1 结果，不代表其他硬件或并发场景。

后续改进方向

- 扩大训练身份覆盖并采用更规范的人脸对齐与数据清洗，以改善 LFW 跨身份泛化。
- 采用卷积静态量化、量化感知训练或支持 INT8 卷积的推理后端，再评估真实端到端收益。
- 在目标部署 CPU 上补充多线程、不同 batch size、吞吐量和峰值内存基准。

下周任务安排

任务	主要内容	预期交付物
任务 7 人脸属性编辑	学习 GAN、StarGAN、AttGAN；使用 CelebA 编辑发色、年龄和性别，并评估 FID / IS。	训练代码与配置；编辑结果图；质量评估报告。
任务 8 3D 人脸重建	使用 PRNet 或 3DDFA_v2 单图重建，并用 PyTorch3D / OpenGL 渲染多视角结果。	重建代码；3D 模型和渲染结果；多角度可视化。

05 交付物

类别	文件
任务 5 Notebook	face_recognition/07_arcface_training.ipynb
任务 6 Notebook	face_recognition/08_model_optimization.ipynb
模型与数据工具	face_recognition/arcface.py
训练配置	face_recognition/arcface_config.json
训练检查点	work_dirs/arcface_resnet50/latest.pth
训练曲线	work_dirs/arcface_resnet50/training_curves.png
训练历史	work_dirs/arcface_resnet50/history.json
LFW 结果	work_dirs/arcface_resnet50/lfw_results.json
优化结果	work_dirs/arcface_resnet50/optimization_results.json
量化模型	output/models/arcface_resnet50_dynamic_int8.pth
ONNX 模型	output/models/arcface_resnet50.onnx
第三周报告	output/pdf/week3_face_recognition_optimization_report.pdf

参考资料

1. He et al., Deep Residual Learning for Image Recognition, CVPR 2016.
2. Deng et al., ArcFace: Additive Angular Margin Loss for Deep Face Recognition, CVPR 2019.
3. Huang et al., Labeled Faces in the Wild, 2007.

GitHub

<https://github.com/xjyyhero/face-vision-lab>

本报告的数值、曲线和表格均来自项目 Notebook 与 work_dirs 中的实际运行结果。

附录 A 过拟合实验记录

正式扩大训练子集之前，先使用 20 万张图像、2,964 个身份训练 20 epochs。该实验的训练集 Accuracy 接近 100%，但 LFW 仅为 71.62%，形成了典型的训练拟合与开放集验证能力不一致现象。

200,000

训练图像

2,964

训练身份

20

训练 epochs

99.99%

最终训练 Accuracy

```
1 train_dataset = MXRecordIODataset(  
2     MSIM_ROOT, transform=train_transform(),  
3     max_samples=MAX_SAMPLES,  
4 )  
5 assert len(train_dataset.classes) >= 2, 'MS-Celeb-1M 子集至少需要两个身份'  
6 train_loader = DataLoader(  
7     train_dataset, batch_size=BATCH_SIZE, shuffle=True,  
8     num_workers=NUM_WORKERS, pin_memory=DEVICE.type == 'cuda', drop_last=True,  
9 )  
10 print(f'训练图像: {len(train_dataset):,}')  
11 print(f'训练身份: {len(train_dataset.classes):,}')  
12 print(f'过滤非图像/损坏记录: {train_dataset.skipped_records:,}')  
3] ✓ 10.2s  
· 训练图像: 200,000  
  训练身份: 2,964  
  过滤非图像/损坏记录: 0
```

过拟合信号

- 平均每个身份约 67.5 张图像。
- 身份种类仅 2,964，覆盖面有限。
- 20 epochs 反复拟合同一批身份。

图 5 首次子集设置与过拟合风险

```
{'epoch': 1, 'loss': 0.660889/350184/44, 'accuracy': 0.99883462/0806658, 'seconds': 94.603/580000204, 'batches': 1562, 'epoch_complete': True}  
Epoch 18/20 开始, margin=0.500, 共 1,562 个 batch  
Epoch 18/20 | batch 1,500/1,562 | Loss 0.3037 | Accuracy 99.96% | 2115 images/s | ETA 0.0h  
{'epoch': 18, 'loss': 0.30350862344889096, 'accuracy': 0.9995998719590269, 'seconds': 94.46859179999956, 'batches': 1562, 'epoch_complete': True}  
Epoch 19/20 开始, margin=0.500, 共 1,562 个 batch  
Epoch 19/20 | batch 1,500/1,562 | Loss 0.1464 | Accuracy 99.98% | 2115 images/s | ETA 0.0h  
{'epoch': 19, 'loss': 0.1473336181198378, 'accuracy': 0.9997899327784892, 'seconds': 94.48890910000046, 'batches': 1562, 'epoch_complete': True}  
Epoch 20/20 开始, margin=0.500, 共 1,562 个 batch  
Epoch 20/20 | batch 1,500/1,562 | Loss 0.0896 | Accuracy 99.99% | 2111 images/s | ETA 0.0h  
{'epoch': 20, 'loss': 0.08950950543295709, 'accuracy': 0.9998649567861716, 'seconds': 94.64387759999954, 'batches': 1562, 'epoch_complete': True}
```

```
> ✓ 0.3s  
1 fig, axes = plt.subplots(1, 2, figsize=(11, 4))  
2 axes[0].plot([row['epoch'] for row in history], [row['loss'] for row in history], marker='o')  
3 axes[0].set(title='ArcFace training loss', xlabel='Epoch', ylabel='Loss')  
4 axes[1].plot([row['epoch'] for row in history], [row['accuracy'] for row in history], marker='o')  
5 axes[1].set(title='Training classification accuracy', xlabel='Epoch', ylabel='Accuracy')  
6 for axis in axes:  
7     axis.grid(alpha=0.3)  
8 plt.tight_layout()  
9 plt.savefig(WORK_DIR / 'training_curves.png', dpi=160)  
10 plt.show()  
11 (WORK_DIR / 'history.json').write_text(json.dumps(history, indent=2), encoding='utf-8')
```





图 6 20 epochs 后训练 Loss 接近 0，训练 Accuracy 接近 100%

附录 A.1 过拟合诊断与修正



LFW Accuracy: 71.6167% ± 1.8560%
各折 Accuracy: [0.7217, 0.7083, 0.6983, 0.7067, 0.7333, 0.72, 0.7517, 0.6867, 0.7017, 0.7333]
目标状态: 未达到 98.5%, 需继续训练或扩大 MS-Celeb-1M 子集

```
1 summary = {  
2     'lfw_accuracy': results['accuracy'],  
3     'lfw_std': results['std'],  
4     'fold accuracies': results['fold accuracies']  
}
```

图 7 首次过拟合实验的 LFW 10 折结果

扩大子集前后对比

指标	首次实验	扩大子集实验	变化
训练图像	200,000	1,000,000	5.00×
训练身份	2,964	12,299	4.15×
训练轮数	20 epochs	10 epochs	减少 50%
训练 Accuracy	99.99%	98.91%	均已充分拟合
LFW Accuracy	71.6167% ± 1.8560%	80.2667% ± 2.2757%	+8.65 pp
训练耗时	约 31.5 min	约 73.0 min	约 2.3×

诊断结论

- 训练 Accuracy 衡量已见身份上的闭集分类，LFW 衡量未见身份之间的开放集验证；前者接近 100% 不能证明后者达到要求。
- 首次实验反复训练 2,964 个身份，模型逐步记忆训练身份，Loss 降至 0.0895，但 LFW 仍只有 71.62%，属于明显过拟合。
 - 将身份覆盖扩大到 12,299、图像扩大到 100 万后，即使训练轮数从 20 减为 10，LFW 仍提升 8.65 个百分点，说明人脸识别更依赖身份多样性，而非只增加同一小子集的训练轮数。
 - 扩大子集后 LFW 仍未达到 98.5%，说明数据覆盖、对齐方式、网络结构与训练预算仍限制泛化性能；最终报告保留真实结果，不以训练 Accuracy 替代验证指标。